

НАБОРИ ОТ ДАННИ: ОТКРИВАНЕ И ЗАРЕЖДАНЕ

Основна идея

В реални задачи често работим с много данни, събрани в набори от данни (dataset). Те могат да бъдат откривани в публични хранилища, изтегляни във формат CSV и зареждани в Python за последваща обработка.

1. Какво е набор от данни?

Набор от данни (dataset) е организирана съвкупност от данни. Най-често данните са представени таблично - в редове и колони. Всеки ред описва отделен запис, а всяка колона - определен признак.

Понятие	Какво означава	Пример
Набор от данни	организирана съвкупност от данни	месечни температури
Запис	един ред от набора	данните за януари
Признак	една характеристика/колона	минимална температура

Защо са важни данните?

Обработката на реални набори от данни е сред основните задачи на съвременните информационни технологии. Данните се използват и за обучение на системи с изкуствен интелект.

2. Откъде можем да намерим набори от данни?

Публичните хранилища предоставят отворени данни, които могат да бъдат изтегляни и използвани за анализ.

Хранилище	Какви данни може да съдържа
Портал за отворени данни на България	население, образование, транспорт, административни данни
Eurostat	статистически данни за държавите от Европейския съюз
Kaggle	набори от данни по множество теми за обучение, анализ и състезания

Задача 1. Намерете набор от данни

Изберете публично хранилище и намерете набор от данни по интересуваща ви тема. Запишете:

Име на набора: _____

Източник: _____

Какво описват данните: _____

Какви колони съдържа: _____

3. Форматът CSV

CSV (Comma-Separated Values) е текстов формат за таблични данни. Всеки ред от файла е запис, а стойностите в колоните са разделени със запетая. Първият ред обикновено съдържа имената на колоните.

```
месец,мин. температура,макс. температура
Януари,-2,12
Февруари,-4,8
Март,-3,14
Април,2,18
Май,5,28
```

Задача 2. Разчетете CSV файла

Отговорете:

Колко колони има? _____

Кои са имената им? _____

Колко записа с данни има? _____

Коя е максималната температура през март? _____

4. Зареждане на CSV файл в Python

За работа с CSV в този урок използваме вградения модул csv. Не е необходимо да се инсталира допълнително.

```
import csv

with open("temperaturi.csv", encoding="utf-8") as f:
    reader = csv.reader(f)
    for red in reader:
        print(red)
```

Какво означават редовете?

- import csv - зарежда готовия модул за работа с CSV;
- open(...) - отваря файла;
- encoding="utf-8" - позволява правилно четене на кирилица;
- csv.reader(f) - създава обект, който чете редовете от файла;
- for red in reader - преминава последователно през всички редове.

Важно

Файлът temperaturi.csv трябва да е в същата папка като програмата, ако в open() е записано само името му. Иначе Python няма да го намери.

5. Зареждане на една колона в списък

Често ни трябва само една колона от набора. Тогава можем да добавяме стойностите от нея в списък и да използваме познатите функции.

```

import csv
temperaturi = []

with open("temperaturi.csv", encoding="utf-8") as f:
    reader = csv.reader(f)
    next(reader)
    for red in reader:
        temperaturi.append(float(red[1]))

print("Средна:", sum(temperaturi) / len(temperaturi))
print("Най-висока:", max(temperaturi))
print("Най-ниска:", min(temperaturi))

```

Новите елементи в този код

Запис	Какво означава
next(reader)	пропуска първия ред със заглавията
red[1]	взема стойността от втората колона на текущия ред
float(red[1])	преобразува прочетения текст в число
append(...)	добавя стойността към списъка

Задача 3. Проследете зареждането

За примерния файл температурите във втората колона са -2, -4, -3, 2 и 5. Какъв списък ще се получи след изпълнение на цикъла?

temperaturi = _____

6. Практическа задача: оценки

Създайте файл `ocenki.csv` със съдържание:

```

предмет,оценка
Математика,5
Информационни технологии,6
Английски език,5

```

Напишете програма, която зарежда оценките от втората колона в списък и извежда:

- броя на предметите;
- средния успех;
- най-високата оценка;
- най-ниската оценка.

Допълнение:

Добавете условие, което извежда „Отличен успех!“, ако средният успех е над 5.50.

7. Практическа задача: температури

Допълнете `temperaturi.csv` с данни за всички месеци. Заредете минималните и максималните температури в два отделни списъка.

- Изведете средната минимална температура.
- Изведете средната максимална температура.
- За всеки месец изчислете температурната амплитуда.
- Намерете най-голямата температурна амплитуда.

8. Често срещани грешки

Грешка	Какво се случва	Как да я избегнем
Файлът е в друга папка	Python не намира файла	поставете файла до програмата или задайте пълен път
Заглавният ред не е пропуснат	опитваме да преобразуваме текст към число	използвайте <code>next(reader)</code>
Избран е грешен индекс на колона	зареждат се други данни	проверете структурата на файла
Липсва <code>float()</code>	числата остават текст	преобразувайте стойността преди обработка
CSV използва различен разделител	колоните не се прочитат както очакваме	проверете файла и настройките на <code>reader</code>

9. Обобщение

Понятие / команда	Най-важното
<code>dataset</code>	организирана съвкупност от данни
CSV	текстов формат за таблични данни
<code>import csv</code>	зарежда модула за CSV
<code>csv.reader()</code>	чете редовете от CSV файл
<code>next(reader)</code>	пропуска заглавния ред
<code>red[1]</code>	избира конкретна колона от текущия ред
<code>open()</code>	отваря файл за четене
Най-важното Преди обработка на данни трябва да разберем структурата им: какви са колоните, има ли заглавен ред, какъв е форматът и кои стойности искаме да използваме.	

10. Провери знанията си

1. Какво е набор от данни (dataset)?
2. Какво означават запис и признак?
3. Посочете три публични хранилища на данни.
4. Как е устроен CSV файл?
5. Защо използваме `encoding="utf-8"`?
6. Какво прави `next(reader)`?
7. Какво означава `red[1]`?
8. Защо преобразуваме прочетената стойност с `float()`?